


3.1 问题一的建模分析与求解

3.1.1 问题描述与总体思路

问题一要求由 100 条英文原始视频构造可直接复核的文本、语音和视觉时序特征。困难不只在三类模态的特征尺度不同，还在于文本由离散词语组成、语音是高频连续波形、视频是图像序列，三者缺少天然一致的采样位置。因此，若先独立抽取定长向量再直接拼接，将无法回答某一特征行究竟对应原视频的哪个时段，也难以区分真实观测、局部无效和序列填充。

为满足完整性、可核验性和可复现性要求，本文建立以原视频绝对时间为主轴的可追溯三模态特征流水线。样本以 video_id 与 clip_id 组成的二元键唯一标识；标签表只用于建立清单和核对样本，不参与特征计算。每条视频先经过媒体探测与音轨解码，再在 0.5 s 统一时间窗上分别聚合词级语义、短时声学描述子和 2 fps 视觉特征，最后将全部序列零填充至 70 窗，并同时保存填充掩码、三模态有效性掩码、窗口边界和原始素材路径。总体流程如图 3-1 所示。

图 3-1 问题一多模态特征提取与时序对齐流程



3.1.2 统一时间轴与符号约定

设一条样本的容器时长为 T 。考虑到题目中最长视频为 34.567 s，本文取时间步长 $\Delta t = 0.5$ s，并将序列上限设为 70，从而覆盖 35 s。第 k 个时间窗及真实窗口数定义为

$$I_k = [k\Delta t, \min((k+1)\Delta t, T)), N = \min(70, \lceil T/\Delta t \rceil), \Delta t = 0.5s. \quad (3-1)$$

其中 $k=0,1,\dots,N-1$ 。所有模态均以 I_k 为唯一时间索引。若媒体流报告的结束时间与容器时长不一致，则使用容器时长建立主时间轴，同时保留各流报告时长和实际可解码帧数用于审计；超出可解码内容的视觉位置保持无效，不补造观测。由此，任何序列位置都能通过 window_start 与 window_end 还原到原视频的绝对时间区间。

3.1.3 三模态情感特征构建

3.1.3.1 文本语义特征

赛题给出的英文转写是唯一正式文本。本文不重新进行自动语音识别，而是利用 WhisperX 对赛题转写和原音轨做强制对齐，得到第 j 个词的起止时间 $[a_j, b_j]$ 及置信分。无法匹配的词仍保留在记录中，但不给出虚构时间。随后使用 RoBERTa-base 最后一层隐状态提取上下文语义；同一词可能被分为多个子词，其词向量取对应子词向量的均值：

$$\mathbf{e}_j = \frac{1}{|S_j|} \sum_{r \in S_j} \mathbf{h}_r, \mathbf{e}_j \in R^{768}. \quad (3-2)$$

其中 S_j 为第 j 个词对应的子词集合， $\mathbf{h}_r$ 为第 r 个子词的最后一层隐向量。对落入时间窗 I_k 的词，按词区间与窗口的重叠长度加权聚合：

$$\mathbf{x}_k^{(T)} = \frac{\sum_j \ell_{jk} \mathbf{e}_j}{\sum_j \ell_{jk}}, \ell_{jk} = |[a_j, b_j) \cap I_k|. \quad (3-3)$$

当分母为 0 时，该窗文本向量置零且 $\text{text_mask}[k]=\text{false}$ ；否则 $\text{text_mask}[k]=\text{true}$ 。该规则允许跨窗词按实际覆盖时长分配语义信息，避免将整个词武断地归入单一窗口。

3.1.3.2 语音韵律特征

原视频音轨经 FFmpeg 解码为 16 kHz、单声道 PCM。采用 openSMILE 的 eGeMAPSv02 LowLevelDescriptors 提取 25 个短时低层描述子，包括响度、基频、谱通量、MFCC、抖动、闪烁、谐噪比和前三个共振峰等。对每个 0.5 s 窗口内的短时帧分别计算均值与标准差并串联：

$$\mathbf{x}_k^{(A)} = [\boldsymbol{\mu}_k; \boldsymbol{\sigma}_k] \in R^{50}, \boldsymbol{\mu}_k = \text{mean}_{q \in I_k} \mathbf{z}_q, \boldsymbol{\sigma}_k = \text{std}_{q \in I_k} \mathbf{z}_q. \quad (3-4)$$

因此语音特征维度为 50。若窗口内无可用短时帧、含非有限值，或音频 RMS 低于 0.001，则将该位置记为静音/无效， $\text{audio_mask}[k]=\text{false}$ ；该窗仍保留在统一时间轴上，不删除样本。

3.1.3.3 视觉表情与姿态特征

视觉分支按 2 fps 从原视频确定性采样，即每个 0.5 s 窗口对应一个采样时刻。OpenFace 2.2.0 输出视线方向与视角 8 维、眼部二维/三维关键点 280 维、头部平移与旋转 6 维、68 点面部二维坐标 136 维，以及面部动作单元强度与出现状态 35 维，共 465 维。仅当 OpenFace 检测成功、置信度不低于 0.80 且全部特征为有限值时，视觉窗口才被视为有效：

$$m_k^{(V)} = \mathbb{I}(s_k = 1) \mathbb{I}(c_k \geq 0.8) \mathbb{I}(\mathbf{x}_k^{(V)} \text{ is finite}). \quad (3-5)$$

检测失败或低置信度只表示该时刻没有可信视觉观测，不解释为‘没有情绪’。对应特征置零并令 $\text{visual_mask}[k]=\text{false}$ ，从而为后续鲁棒建模保留真实的局部缺失信息。

3.1.4 跨模态时序对齐与定长组织

三条分支最终都映射到同一组 I_k 。文本使用词区间与 I_k 的重叠长度，语音使用短时帧起点所属窗口，视觉使用 2 fps 采样序号与窗口序号的一一对应关系。对文本、语音和视觉任一模态，先计算该模态的有效掩码，再与真实时间轴掩码共同约束特征：

$$\tilde{\mathbf{x}}_k^{(m)} = m_k^{(m)} m_k^{(P)} \mathbf{x}_k^{(m)}, m \in \{T, A, V\}. \quad (3-6)$$

其中真实时间轴掩码取 1 表示 $k < N$ ，反之为填充位置。最终三模态矩阵的形状统一为

$$\mathbf{X}^{(T)} \in R^{70 \times 768}, \mathbf{X}^{(A)} \in R^{70 \times 50}, \mathbf{X}^{(V)} \in R^{70 \times 465}. \quad (3-7)$$

固定形状便于批量建模，但零值本身不能判断该位置是否有效，读取时必须联合 `padding_mask` 与相应的 `text_mask`、`audio_mask` 或 `visual_mask`。该双层掩码机制同时区分了‘视频已结束’与‘视频仍在继续但当前模态不可用’两种情况。

3.1.5 特征文件规范与追溯设计

每条样本单独存放于 `outputs/samples/<video_id>__<clip_id>/`，主特征采用压缩 NPZ 格式，浮点特征统一为 float32，掩码统一为布尔类型。NPZ 中同时写入样本主键、源标签行号、原始时长、真实窗口数、70 个窗口的起止时间和四类掩码。配套 JSON 与 CSV 保存模型、特征名、媒体属性、词级时间戳、帧级检测状态和阶段日志，形成‘特征行—时间窗—原始词/帧—源视频’的追溯链。各文件作用见表 3-1。

表 3-1 自生成特征文件的组织结构与用途

文件	主要字段	核验用途
features.npz	三模态矩阵、四类掩码、窗口边界、有效长度及样本主键	模型读取的主文件
metadata.json	媒体信息、特征名、模型与聚合规则、只读标签	解释维度与参数
word_alignment.csv	词序号、词文本、起止时间、置信度与有效标志	文本回溯
timeline.json	统一时间轴上的词、采样帧、人脸置信度与静音窗	跨模态核验
status.json	处理签名、分阶段状态、告警、错误和工具版本	断点续跑与审计
summary.csv	100 条样本的宽表汇总	论文统计
modality_summary.csv	样本×模态的 300 行长表	全量逐模态清单

3.1.6 典型样本的时序对齐验证

从成功样本中自动选择三模态覆盖完整、词级对齐质量较高的-dxfTGcXJoc__6 作为典型样本。该视频时长 12.967 s，对应 26 个真实窗口；27 个转写词全部获得有效起止时间。图 3-2 在同一原视频横轴上依次展示 4 个实际视频帧、词级区间、原始音频波形、窗口级 F0 半音均值、OpenFace 动作单元 AU12_r 以及三模态覆盖掩码。浅蓝色区域给出一个三模态同时有效的 0.5 s 窗口，灰色斜线表示无效或越出真实时长的位置。

图 3-2 典型样本的文本 语音 视觉时序对应关系




表 3-2 典型样本的对齐核验结果

项目	核验结果
样本主键	-dxFTGcXJoc_6
原始时长与序列	12.967 s, 26 个真实窗口
文本	27/27 个词得到有效时间戳, 25 个窗口有效
语音	26 个窗口有效, 图中展示 F0 半音均值
视觉	25 个窗口有效, 图中展示 AU12_r
综合覆盖	三模态窗口覆盖率均值 97.4%

图中词区间与音频波形的发声片段相互对应, 视频帧时刻与视觉序列位置严格遵循 2 fps 规则; 三模态均可由窗口索引还原到原素材。该样本的文本、语音和视觉有效窗分别为 25、26 和 25, 平均覆盖率为 97.4%, 说明统一时间轴没有改变各模态的原始时序关系。

3.1.7 全量提取结果与质量核验

程序对标签表与视频目录进行双向核对，100 行标签均找到唯一视频，未发现重复主键、缺失视频、额外无标签视频、空文本或越界情感强度。全部 100 条样本均完成媒体探测、文本对齐、语音提取、视觉提取和文件写入，状态均为 success。主要统计结果见表 3-3。

表 3-3 问题一全量特征提取与质量统计

统计项目	结果	说明
样本覆盖	100/100	标签行与视频文件一一匹配，重复键与缺失视频均为 0
视频时长	2.648--34.567 s	平均 11.201 s，中位数 10.384 s
统一序列	0.5 s/窗，最多 70 窗	真实时间窗合计 2287 个
文本特征	70×768	有效窗 1814 个；有效对齐词 1920/1932
语音特征	70×50	有效非静音窗 1538 个
视觉特征	70×465	有效窗 1411 个；通过阈值帧 1411/1570
质量核验	全部通过	形状、有限值、掩码、填充、时间越界与追溯文件检查均通过

在 1 932 个对齐词中，1 920 个具有有效时间戳，对齐有效率为 99.38%；其余 12 个词分布在 9 条样本中，均保留原词并将相应位置记为无时间戳。视觉分支实际获得 1 570 个采样帧，其中 1 411 个通过检测成功与 0.80 置信度阈值，有效率为 89.87%。所有词时间和帧时间的越界数均为 0。按统一时间轴统计，100 条样本共有 2 287 个真实窗口，文本、语音和视觉分别有 1 814、1 538 和 1 411 个有效窗口。视觉流短于容器时长或人脸不可见所造成的空窗均由掩码记录，未删除任何原始样本。

表 3-4 附件 1 全部 100 条样本的特征提取结果

注：三模态特征维度固定为 T/A/V=768/50/465，对齐粒度固定为 0.5 s；N 为真实时间窗数，T、A、V 分别为三模态有效窗数。

序号	样本编号	时长/s	N	T	A	V	状态
1	-3g5yACwYnA__13	8.767	18	12	10	11	成功
2	-3g5yACwYnA__3	19.273	39	29	28	29	成功
3	-3g5yACwYnA__2	14.234	29	17	18	19	成功
4	-3g5yACwYnA__9	16.234	33	25	17	18	成功
5	-3nNcZdcdvU__5	10.937	22	19	16	16	成功
6	-HwX2H8Z4hY__2	8.151	17	7	8	3	成功
7	-HwX2H8Z4hY__5	11.467	23	18	11	5	成功
8	-HwX2H8Z4hY__6	6.767	14	9	7	5	成功
9	-HwX2H8Z4hY__9	11.434	23	21	16	5	成功
10	-NFrJFQijFE__1	9.120	19	12	12	0	成功
11	-NFrJFQijFE__2	9.760	20	14	14	0	成功
12	-THoVjtlkeU__12	18.800	38	30	30	30	成功
13	-THoVjtlkeU__2	4.644	10	8	9	9	成功
14	-THoVjtlkeU__6	11.067	23	20	16	16	成功

序号	样本编号	时长/s	N	T	A	V	状态
15	-UuX1xuaiiE__1	13.434	27	23	21	21	成功
16	-UuX1xuaiiE__0	3.700	8	7	8	7	成功
17	-UuX1xuaiiE__3	10.634	22	16	8	8	成功
18	-UuX1xuaiiE__6	15.234	31	24	16	16	成功
19	-a55Q6RWvTA__3	22.617	46	41	45	44	成功
20	-aNfi7CP8vM__7	11.334	23	20	17	16	成功
21	-aqamKhZ1Ec__0	11.000	22	19	22	21	成功
22	-dxftGcXJoc__1	19.700	40	37	32	31	成功
23	-dxftGcXJoc__0	20.534	42	35	39	28	成功
24	-dxftGcXJoc__2	19.552	40	37	34	31	成功
25	-dxftGcXJoc__6	12.967	26	25	26	25	成功
26	-egA8-b7-3M__26	11.500	23	18	12	12	成功
27	-egA8-b7-3M__17	14.000	28	21	15	15	成功
28	-egA8-b7-3M__18	13.367	27	24	17	15	成功
29	-egA8-b7-3M__16	7.129	15	12	11	11	成功
30	-egA8-b7-3M__13	6.967	14	11	8	8	成功
31	-egA8-b7-3M__1	11.534	24	21	21	17	成功
32	-egA8-b7-3M__6	8.035	17	14	13	12	成功
33	-egA8-b7-3M__9	10.134	21	16	10	10	成功
34	-egA8-b7-3M__20	14.767	30	23	13	13	成功
35	-iRBcNs9oI8__3	5.840	12	5	11	11	成功
36	-iRBcNs9oI8__7	5.806	12	9	8	8	成功
37	-iRBcNs9oI8__6	7.475	15	4	6	5	成功
38	-iRBcNs9oI8__9	7.152	15	6	5	5	成功
39	-iRBcNs9oI8__8	8.642	18	11	15	16	成功
40	-IzEya4AM_4__5	7.800	16	12	16	14	成功
41	-IzEya4AM_4__6	22.733	46	42	30	29	成功
42	-mJ2ud6oKI8__1	6.574	14	3	0	0	成功
43	-mJ2ud6oKI8__2	6.781	14	5	0	0	成功
44	-mJ2ud6oKI8__6	2.648	6	3	5	4	成功
45	-mJ2ud6oKI8__9	10.010	21	16	14	14	成功
46	-mJ2ud6oKI8__8	8.662	18	8	9	8	成功
47	-mqbVkbCndg__0	6.500	13	12	13	13	成功
48	-t217m2on-s__2	8.011	17	12	10	10	成功
49	-t217m2on-s__7	18.700	38	34	32	32	成功
50	-tANM6ETI_M__3	9.100	19	16	14	13	成功
51	-tPCytz4rww__11	8.000	16	14	11	11	成功
52	-tPCytz4rww__10	11.734	24	17	10	10	成功
53	-tPCytz4rww__12	18.767	38	33	24	24	成功

序号	样本编号	时长/s	N	T	A	V	状态
54	-tPCytz4rww__16	13.236	27	20	15	14	成功
55	-tPCytz4rww__18	14.281	29	23	14	12	成功
56	-vxjVxOeScU__4	11.734	24	21	18	16	成功
57	-wMB_hJL-3o__7	7.315	15	13	12	11	成功
58	-wny0OAz3g8__1	9.100	19	16	14	14	成功
59	-wny0OAz3g8__0	3.334	7	6	7	7	成功
60	-wny0OAz3g8__3	11.169	23	20	13	12	成功
61	-wny0OAz3g8__2	11.934	24	22	13	13	成功
62	-wny0OAz3g8__5	9.967	20	18	14	13	成功
63	-wny0OAz3g8__7	9.500	19	18	16	16	成功
64	-wny0OAz3g8__9	9.867	20	19	12	12	成功
65	-571d8cVauQ__0	5.167	11	8	9	9	成功
66	-571d8cVauQ__5	18.500	37	33	31	31	成功
67	-I_e4mlh0yE__1	10.767	22	17	15	15	成功
68	-I_e4mlh0yE__3	9.300	19	16	18	18	成功
69	-UacrmKiTn4__10	12.634	26	21	14	15	成功
70	-UacrmKiTn4__4	6.223	13	10	10	9	成功
71	-hnBHBn8p5A__7	9.176	19	10	15	11	成功
72	-hnBHBn8p5A__6	11.429	23	13	13	6	成功
73	-qDkUB0GgYY__6	9.683	20	15	10	9	成功
74	-uywlfYOS8__4	14.334	29	26	12	12	成功
75	-6rXp3zJ3kc__8	16.580	34	28	26	24	成功
76	-9y-fZ3swSY__0	6.900	14	12	14	13	成功
77	-9y-fZ3swSY__4	9.334	19	16	6	6	成功
78	-9y-fZ3swSY__8	10.775	22	18	10	10	成功
79	-AUZQgSxyPQ__2	27.300	55	51	45	45	成功
80	-HeZS2-Prhc__2	15.834	32	24	17	16	成功
81	-MeTTeMJBnc__0	9.334	19	16	19	17	成功
82	-MeTTeMJBnc__13	7.467	15	13	10	11	成功
83	-MeTTeMJBnc__7	17.367	35	31	21	19	成功
84	-RfYyzHpjk4__11	11.700	24	19	10	10	成功
85	-RfYyzHpjk4__8	11.657	24	19	9	8	成功
86	-RfYyzHpjk4__2	6.234	13	11	10	11	成功
87	-UUCSKoHeMA__0	7.867	16	13	15	15	成功
88	-ri04Z7vwnc__0	3.295	7	5	6	0	成功
89	-ri04Z7vwnc__2	6.966	14	14	12	0	成功
90	-ri04Z7vwnc__5	5.965	12	5	7	7	成功
91	-s9qJ7ATP7w__1	10.900	22	14	10	10	成功
92	-s9qJ7ATP7w__0	6.867	14	13	14	14	成功

序号	样本编号	时长/s	N	T	A	V	状态
93	-s9qJ7ATP7w__5	13.567	28	23	17	17	成功
94	-s9qJ7ATP7w__4	6.200	13	10	9	7	成功
95	-s9qJ7ATP7w__7	12.767	26	20	14	10	成功
96	-s9qJ7ATP7w__6	6.600	14	6	5	4	成功
97	-s9qJ7ATP7w__8	6.600	14	10	7	7	成功
98	-yRb-Jum7EQ__1	34.567	70	61	52	55	成功
99	-yRb-Jum7EQ__5	13.634	28	25	25	25	成功
100	-yRb-Jum7EQ__6	15.488	31	25	20	21	成功

3.1.8 可复现性与异常处理规则

关键参数集中写入 config.yaml，执行顺序固定为清单扫描、环境预检、单样本试跑、全量运行、质量核验和典型样本绘图。程序以配置、视频大小与修改时间、转写文本及流水线版本计算处理签名；签名不变且状态成功的样本可安全断点续跑，参数改变则自动重新处理。随机种子固定为 2026。工具版本与关键参数见表 3-5。

表 3-5 问题一复现实验环境与关键参数

类别	版本与参数
运行环境	Ubuntu 22.04; Python 3.8.20; 随机种子 2026
媒体处理	FFmpeg/FFprobe 4.4.2; 音频 16 kHz 单声道 PCM
文本	WhisperX 3.2.0; RoBERTa-base; Transformers 4.39.3; PyTorch 2.4.1
语音	openSMILE 2.5.0; eGeMAPSv02 LowLevelDescriptors
视觉	OpenFace 2.2.0; 2 fps; 人脸置信度阈值 0.80
数据依赖	NumPy 1.24.3; pandas 2.0.3; openpyxl 3.1.5; SoundFile 0.12.1

异常处理遵循‘保留原样本、显式标记、禁止替代’原则：词无法对齐时不伪造时间；静音、非有限声学帧和低置信度人脸均只关闭相应模态掩码；视频流时长冲突时保留容器时长、流结束时间和实际解码数量；工具或固定模型不可用时记录失败并继续处理其他样本，不以语义不同的特征替代。质量控制程序逐样本检查矩阵形状、数值有限性、零填充、掩码逻辑、时间边界、主键一致性和追溯文件完整性，最终报告 structural_checks_passed=true、extraction_complete=true。

3.1.9 问题一小结

本文完成了附件 1 全部 100 条视频的三模态情感特征构建。以 0.5 s 原视频时间窗为公共坐标，将 RoBERTa 文本语义、eGeMAPS 声学统计和 OpenFace 视觉行为统一组织为 70 步定长序列，并用填充掩码与模态掩码保存真实有效性。全量样本、全部模态文件和窗口位置均可追溯至原视频，典型样本验证与质量报告共同表明该特征集满足覆盖完整、时序可核验和过程可复现三项要求，可作为问题二和问题三的统一输入接口。

问题一相关参考文献

- [1] Liu Y, Ott M, Goyal N, et al. RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv:1907.11692, 2019.
- [2] Bain M, Huh J, Han T, et al. WhisperX: Time-Accurate Speech Transcription of Long-Form Audio. INTERSPEECH, 2023: 4489-4493.
- [3] Eyben F, Wöllmer M, Schuller B. openSMILE: The Munich Versatile and Fast Open-Source Audio Feature Extractor. ACM Multimedia, 2010: 1459-1462.
- [4] Eyben F, Scherer K R, Schuller B W, et al. The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing. IEEE Transactions on Affective Computing, 2016, 7(2): 190-202.
- [5] Baltrušaitis T, Zadeh A, Lim Y C, et al. OpenFace 2.0: Facial Behavior Analysis Toolkit. IEEE International Conference on Automatic Face and Gesture Recognition, 2018: 59-66.